

# Testes de hipótese em Modelos Multivariados de Covariância Linear Generalizada (McGLM)

Lineu Alberto Cavazani de Freitas  
Orientador: Prof. Dr. Wagner Hugo Bonat

PPG Informática  
Data Science & Big Data  
Universidade Federal do Paraná

<https://lineu96.github.io/st/>  
[lineuacf@gmail.com](mailto:lineuacf@gmail.com)

1

Quem sou eu

# McGLM

TH MCGLM

Lineu Alberto

Quem sou eu

Introdução

McGLM

Estimação e inferência

Teste Wald

Construção da matriz L

ANOVA via teste Wald

Funções implementadas

Próximos passos

## Quem sou eu

- ▶ Estatístico formado pela **Universidade Federal do Paraná (UFPR)** em 2019.
- ▶ Atualmente mestrando no **Programa de Pós Graduação em Informática da UFPR**.
- ▶ Inserido na área de concentração Ciência da Computação, linha de pesquisa Tecnologia da Informação e grupo de pesquisa **Data Science & Big Data**.



## Sumário

1. Introdução
2. McGLM
3. Estimação e inferência
4. Teste Wald
5. Construção da matriz L
6. ANOVA via teste Wald
7. Funções implementadas
8. Próximos passos

Quem sou eu

Introdução

McGLM

Estimação e inferência

Teste Wald

Construção da matriz L

ANOVA via teste Wald

Funções implementadas

Próximos passos

## 2

# Introdução

## Onde tudo começou

- ▶ O projeto teve início em 2018 quando eu e uma colega de curso ([Jhenifer Caetano Veloso](#)), desenvolvemos nosso TCC sob orientação do professor Wagner.
- ▶ O título do trabalho foi "[Análise de Variância Multivariada para Dados Não Gaussianos via Teste Wald](#)".

TH MCGLM

Lineu Alberto

Quem sou eu

Introdução

McGLM

Estimação e inferência

Teste Wald

Construção da matriz  $L$

ANOVA via teste Wald

Funções implementadas

Próximos passos



## Plano para o mestrado

- ▶ Na graduação avaliamos o teste Wald para gerar quadros de análise de variância multivariadas do tipo III (MANOVA).
- ▶ A ideia é dar continuidade e ampliar o foco do trabalho que teve início na graduação.
- ▶ O título atual do trabalho é "Testes de hipótese em Modelos Multivariados de Covariância Linear Generalizada (McGLM)".
- ▶ Nosso objetivo é explorar o teste Wald para testar hipóteses gerais sobre parâmetros de regressão, dispersão ou potência de um McGLM.
- ▶ Bem como obter quadros de ANOVA e MANOVA para parâmetros de regressão e dispersão.



## As etapas do trabalho são:

- ▶ Adaptar o teste Wald para realização de testes de hipótese gerais sobre parâmetros de Modelos Multivariados de Covariância Linear Generalizada (McGLM).
- ▶ Implementar funções para efetuar tais testes, bem como funções para efetuar Análises de Variância e Análises de Variância Multivariadas para os McGLM.
- ▶ Demonstrar as propriedades e comportamento dos testes propostos com base em estudos de simulação.
- ▶ Demonstrar o potencial de aplicação das metodologias discutidas com base na aplicação a conjuntos de dados reais.

3

McGLM

## Para definição de um McGLM considere:

- ▶  $Y_{N \times R} = \{Y_1, \dots, Y_R\}$  uma matriz de variáveis resposta.
- ▶  $M_{N \times R} = \{\mu_1, \dots, \mu_R\}$  uma matriz de valores esperados.
- ▶  $\Sigma_r$ ,  $r = 1, \dots, R$ , a matriz de variância e covariância para cada resposta  $r$ , de dimensão  $N \times N$ .
- ▶  $\Sigma_b$  uma matriz de correlação, de ordem  $R \times R$ , que descreve a correlação entre as variáveis resposta.
- ▶  $X_r$  denota uma matriz de delineamento  $N \times k_r$ .
- ▶  $\beta_r$  denota um vetor  $k_r \times 1$  de parâmetros de regressão.

Os McGLMs são definidos por:

$$E(Y) = M = \{g_1^{-1}(X_1\beta_1), \dots, g_R^{-1}(X_R\beta_R)\}$$
$$\text{Var}(Y) = C = \Sigma_R \overset{G}{\otimes} \Sigma_b$$

Em que:

- ▶  $\Sigma_R \overset{G}{\otimes} \Sigma_b = \text{Bdiag}(\tilde{\Sigma}_1, \dots, \tilde{\Sigma}_R)(\Sigma_b \otimes I)\text{Bdiag}(\tilde{\Sigma}_1^\top, \dots, \tilde{\Sigma}_R^\top)$  é o produto generalizado de Kronecker.
- ▶  $\tilde{\Sigma}_r$  denota a matriz triangular inferior da decomposição de Cholesky da matriz  $\Sigma_r$ .
- ▶  $\text{Bdiag}()$  denota a matriz bloco-diagonal.
- ▶  $I$  uma matriz identidade  $N \times N$ .
- ▶  $g_r()$  são as tradicionais funções de ligação.

## Matriz de variância e covariância

- ▶ Para variáveis resposta contínuas, binárias, binomiais, proporções ou índices a matriz de variância e covariância  $\Sigma_r$  é dada por:

$$\Sigma_r = V(\mu_r; p_r)^{1/2} (\Omega(\tau_r)) V(\mu_r; p_r)^{1/2}$$

- ▶ No caso de variáveis resposta que sejam contagens a matriz de variância e covariância para cada variável resposta fica dada por:

$$\Sigma_r = \text{diag}(\mu_r) + V(\mu_r; p_r)^{1/2} (\Omega(\tau_r)) V(\mu_r; p_r)^{1/2}$$

- ▶  $V(\mu_r; p_r) = \text{diag}(\vartheta(\mu_r; p_r))$  denota uma matriz diagonal na qual as entradas são dadas pela função de variância  $\vartheta(\cdot; p_r)$  aplicada aos elementos do vetor  $\mu_r$ .

## Função de variância

- ▶ Função de variância potência:
  - ▶ Caracteriza a família Tweedie de distribuições.
  - ▶ É dada por  $\vartheta(\cdot; p_\tau) = \mu_\tau^{p_\tau}$ .
  - ▶ Casos particulares: Normal ( $p = 0$ ), Poisson ( $p = 1$ ), gama ( $p = 2$ ) e Normal inversa ( $p = 3$ ).
- ▶ Função de dispersão Poisson–Tweedie:
  - ▶ Visa contornar a inflexibilidade da utilização da função de variância potência para respostas que caracterizam contagens.
  - ▶ É dada por  $\vartheta(\cdot; p) = \mu + \tau\mu^p$  em que  $\tau$  é o parâmetro de dispersão.
  - ▶ Casos particulares: Hermite ( $p = 0$ ), Neyman tipo A ( $p = 1$ ), binomial negativa ( $p = 2$ ) e Poisson–inversa gaussiana ( $p = 3$ ).
- ▶ Função de variância binomial:
  - ▶ Indicada quando a variável resposta é binária, restrita a um intervalo ou quando tem-se o número de sucessos em um número de tentativas.
  - ▶ É dada por  $\vartheta(\cdot; p_\tau) = \mu_\tau^{p_\tau 1} (1 - \mu_\tau)^{p_\tau 2}$

## Parâmetro de potência

- ▶ O parâmetro de potência  $p$  aparece em todas as funções de variância discutidas.
- ▶ Este parâmetro tem especial importância pois trata-se de um índice que distingue diferentes distribuições de probabilidade.
- ▶ Pode ser utilizado como uma ferramenta para seleção automática da distribuição de probabilidade que mais se adequa ao problema.

## Preditor linear matricial

- ▶ A matriz de dispersão  $\mathbf{\Omega}(\boldsymbol{\tau})$  descreve a parte da covariância dentro de cada variável resposta que não depende da estrutura média.
- ▶ Isto é, a estrutura de correlação entre as observações da amostra.
- ▶ A matriz de dispersão é modelada através de um preditor linear matricial combinado com uma função de ligação de covariância.
- ▶ O preditor linear matricial é dado por:

$$h\{\mathbf{\Omega}(\boldsymbol{\tau}_r)\} = \tau_{r0}Z_0 + \dots + \tau_{rD}Z_D$$

- ▶  $h()$  é a função de ligação de covariância.
- ▶  $Z_{rd}$  com  $d = 0, \dots, D$  são matrizes que representam a estrutura de covariância presente em cada variável resposta  $r$ .
- ▶  $\boldsymbol{\tau}_r = (\tau_{r0}, \dots, \tau_{rD})$  é um vetor  $(D + 1) \times 1$  de parâmetros de dispersão.



## Comentários sobre a classe

- ▶ Os McGLM configuram uma estrutura geral para análise via modelos de regressão.
- ▶ Comporta múltiplas respostas não gaussianas.
- ▶ Não se faz suposições quanto à independência das observações.

# 4

## Estimação e inferência

## Funções de estimação

As funções de estimação para os parâmetros de regressão (função quasi-score) e de dispersão (função de estimação de Pearson) são dadas por:

$$\begin{aligned}\psi_{\beta}(\beta, \lambda) &= \mathbf{D}^{\top} \mathbf{C}^{-1}(\mathbf{y} - \mathcal{M}) \\ \psi_{\lambda_i}(\beta, \lambda) &= \text{tr}(\mathbf{W}_{\lambda_i}(\mathbf{r}^{\top} \mathbf{r} - \mathbf{C})), i = 1, \dots, Q\end{aligned}$$

Em que:

- ▶  $\beta_r$  denota um vetor  $k_r \times 1$  de parâmetros de regressão.
- ▶  $\lambda$  é um vetor  $Q \times 1$  de parâmetros de dispersão.
- ▶  $\mathbf{y}$  é um vetor  $NR \times 1$  com os valores da matriz de variáveis respostas  $\mathbf{Y}_{N \times R}$  empilhados.
- ▶  $\mathcal{M}$  é um vetor  $NR \times 1$  com os valores da matriz de valores esperados  $\mathbf{M}_{N \times R}$  empilhados.
- ▶  $\mathbf{D} = \nabla_{\beta} \mathcal{M}$  é uma matriz  $NR \times K$ , e  $\nabla_{\beta}$  denota o operador gradiente.
- ▶  $\mathbf{W}_{\lambda_i} = -\frac{\partial \mathbf{C}^{-1}}{\partial \lambda_i}$
- ▶  $\mathbf{r} = (\mathbf{y} - \mathcal{M})$

## Distribuição assintótica e algoritmo de estimação

- ▶ Para resolver o sistema de equações  $\psi_{\beta} = 0$  e  $\psi_{\lambda} = 0$  faz-se uso do algoritmo Chaser modificado:

$$\begin{aligned}\beta^{(i+1)} &= \beta^{(i)} - S_{\beta}^{-1} \psi_{\beta}(\beta^{(i)}, \lambda^{(i)}), \\ \lambda^{(i+1)} &= \lambda^{(i)} - S_{\lambda}^{-1} \psi_{\lambda}(\beta^{(i+1)}, \lambda^{(i)}).\end{aligned}$$

- ▶ Seja  $\hat{\theta} = (\hat{\beta}^{\top}, \hat{\lambda}^{\top})^{\top}$  o estimador baseado em funções de estimação de  $\theta$ .
- ▶ A distribuição assintótica de  $\hat{\theta}$  é:

$$\hat{\theta} \sim N(\theta, J_{\theta}^{-1}),$$

$J_{\theta}^{-1}$  é a inversa da matriz de informação de Godambe, dada por

$$J_{\theta}^{-1} = S_{\theta}^{-1} V_{\theta} S_{\theta}^{-\top},$$

em que  $S_{\theta}^{-\top} = (S_{\theta}^{-1})^{\top}$ .

5

# Teste Wald

## Teste Wald

- ▶ E um teste de hipóteses largamente empregado para avaliar suposições sobre parâmetros de um modelo de regressão.
- ▶ Isto é, verificar se existe evidência suficiente para afirmar que o parâmetro é ou não estatisticamente igual a um valor qualquer.

## Teste Wald

- ▶ A grosso modo, é um teste que avalia a distância entre a estimativa do parâmetro e o valor postulado sob a hipótese nula.
- ▶ Esta diferença é ainda ponderada por uma medida de precisão da estimativa do parâmetro.
- ▶ Quanto mais distante de 0 for o valor da distância ponderada, menor é a chance da hipótese de igualdade ser verdadeira, ou seja, do valor postulado ser igual ao valor estimado.

## Teste Wald

- ▶ Além destes elementos o teste pressupõe que os estimadores dos parâmetros do modelo sigam distribuição assintótica Normal.
- ▶ Para avaliação da estatística de teste e verificação de significância estatística utiliza-se distribuição assintótica Qui-quadrado ( $\chi^2$ ).



## Hipóteses

As hipóteses a serem testadas podem ser escritas como:

$$H_0 : L\theta_{\beta,\tau,p} = c \text{ vs } H_1 : L\theta_{\beta,\tau,p} \neq c.$$

Em que:

- ▶ Em que  $L$  é a matriz de especificação das hipóteses a serem testadas, tem dimensão  $s \times h$ .
- ▶  $\theta_{\beta,\tau,p}$  é o vetor de dimensão  $h \times 1$  de parâmetros de regressão, dispersão e potência do modelo.
- ▶  $c$  é um vetor de dimensão  $s \times 1$  com os valores sob hipótese nula.

## Estatística de teste

A generalização da estatística de teste para verificar a validade de uma hipótese sobre parâmetros de um McGLM é dada por:

$$W = (\mathbf{L}\hat{\boldsymbol{\theta}}_{\beta,\tau,p} - \mathbf{c})^T (\mathbf{L} \mathbf{J}_{\beta,\tau,p}^{-1} \mathbf{L}^T)^{-1} (\mathbf{L}\hat{\boldsymbol{\theta}}_{\beta,\tau,p} - \mathbf{c}).$$

Em que:

- ▶  $\mathbf{L}$  é a mesma matriz da especificação das hipóteses a serem testadas, tem dimensão  $s \times h$ .
- ▶  $\hat{\boldsymbol{\theta}}_{\beta,\tau,p}$  é o vetor de dimensão  $h \times 1$  com todas as estimativas dos parâmetros de regressão, dispersão e potência do modelo.
- ▶  $\mathbf{c}$  é um vetor de dimensão  $s \times 1$  com os valores sob hipótese nula.
- ▶  $\mathbf{J}_{\beta,\tau,p}^{-1}$  é a inversa da matriz de informação de Godambe desconsiderando os parâmetros de correlação, de dimensão  $h \times h$ .

## A matriz L

- ▶ Cada coluna da matriz L corresponde a um dos  $h$  parâmetros do modelo e cada linha a uma hipótese.
- ▶ Sua construção consiste basicamente em preencher a matriz com 0, 1 e eventualmente -1 de tal modo que o produto  $L\theta_{\beta,\tau,p}$  represente corretamente a hipótese de interesse.

## Comentários finais

- ▶ É possível testar qualquer parâmetro individualmente ou até mesmo formular hipóteses para diversos parâmetros simultaneamente, sejam eles de regressão, dispersão ou potência.
- ▶ Independente do número de parâmetros testados, a estatística de teste  $W$  é um único valor que segue assintoticamente distribuição  $\chi^2$ .
- ▶ Os graus de liberdade são dados pelo número de parâmetros testados, isto é, o número de linhas da matriz  $L$ , denotado por  $s$ .

6

# Construção da matriz L

## Exemplos de hipóteses que podem ser testadas.

Considere um modelo bivariado genérico, com preditor dado por:

$$g_r(\mu_r) = \beta_{r0} + \beta_{r1}x_1$$

- ▶ O índice  $r$  denota a variável resposta,  $r = 1, 2$ .
- ▶  $\beta_{r0}$  representa o intercepto.
- ▶  $\beta_{r1}$  um parâmetro de regressão associado a uma variável  $x_1$ .
- ▶ Considere que cada resposta possui apenas um parâmetro de dispersão:  $\tau_{r1}$ .
- ▶ Considere que os parâmetros de potência foram fixados.

## Exemplo 1

Considere a hipótese:

$$H_0 : \beta_{11} = 0 \text{ vs } H_1 : \beta_{11} \neq 0.$$

Esta hipótese pode ser reescrita na seguinte notação:

$$H_0 : \mathbf{L}\boldsymbol{\theta}_{\beta,\tau,p} = \mathbf{c} \text{ vs } H_1 : \mathbf{L}\boldsymbol{\theta}_{\beta,\tau,p} \neq \mathbf{c}.$$

Em que:

- ▶  $\boldsymbol{\theta}_{\beta,\tau,p}^T = [\beta_{10} \ \beta_{11} \ \beta_{20} \ \beta_{21} \ \tau_{11} \ \tau_{21}]$ .
- ▶  $\mathbf{L} = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 \end{bmatrix}$ .
- ▶  $\mathbf{c} = [0]$ , é o valor da hipótese nula.

## Exemplo 2

Considere a hipótese:

$$H_0 : \beta_{r1} = 0 \text{ vs } H_1 : \beta_{r1} \neq 0.$$

Ou, da mesma forma:

$$H_0 : \begin{pmatrix} \beta_{11} \\ \beta_{21} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \text{ vs } H_1 : \begin{pmatrix} \beta_{11} \\ \beta_{21} \end{pmatrix} \neq \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$



## Exemplo 2

A hipótese pode ser reescrita na seguinte notação:

$$H_0 : \mathbf{L}\boldsymbol{\theta}_{\beta,\tau,p} = \mathbf{c} \text{ vs } H_1 : \mathbf{L}\boldsymbol{\theta}_{\beta,\tau,p} \neq \mathbf{c}.$$

Em que:

- ▶  $\boldsymbol{\theta}_{\beta,\tau,p}^T = [\beta_{10} \ \beta_{11} \ \beta_{20} \ \beta_{21} \ \tau_{11} \ \tau_{21}]$ .
- ▶  $\mathbf{L} = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{bmatrix}$
- ▶  $\mathbf{c} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ , é o valor da hipótese nula.

### Exemplo 3

Considere a hipótese:

$$H_0 : \beta_{11} - \beta_{21} = 0 \text{ vs } H_1 : \beta_{11} - \beta_{21} \neq 0.$$

Esta hipótese pode ser reescrita na seguinte notação:

$$H_0 : \mathbf{L}\boldsymbol{\theta}_{\beta,\tau,p} = \mathbf{c} \text{ vs } H_1 : \mathbf{L}\boldsymbol{\theta}_{\beta,\tau,p} \neq \mathbf{c}.$$

Em que:

- ▶  $\boldsymbol{\theta}_{\beta,\tau,p}^T = [\beta_{10} \ \beta_{11} \ \beta_{20} \ \beta_{21} \ \tau_{11} \ \tau_{21}]$ .
- ▶  $\mathbf{L} = \begin{bmatrix} 0 & 1 & 0 & -1 & 0 & 0 \end{bmatrix}$ .
- ▶  $\mathbf{c} = [0]$ , é o valor da hipótese nula.

7

# ANOVA via teste Wald

## A análise de variância

- ▶ Consiste em efetuar testes sucessivos impondo restrições ao modelo original.
- ▶ O objetivo é testar se a ausência de determinada variável gera perda ao modelo.
- ▶ Os resultados destes sucessivos testes são sumarizados numa tabela que contém em cada linha:
  - ▶ A variável.
  - ▶ O valor de uma estatística de teste.
  - ▶ Os graus de liberdade.
  - ▶ E um p-valor.

## Precauções

- ▶ Cuidados devem ser tomados no que diz respeito à forma como o quadro foi elaborado.
- ▶ Cada linha do quadro refere-se a uma hipótese e estas hipóteses podem ser elaboradas de formas distintas.
- ▶ Formas conhecidas de se elaborar o quadro são as chamadas ANOVAs do tipo I, II e III.
- ▶ Esta nomenclatura vem do software estatístico SAS, contudo as implementações não necessariamente correspondem ao que está implementado no SAS.
- ▶ Recomenda-se ao usuário estar seguro de qual tipo de análise está sendo utilizada pois, caso contrário, interpretações equivocadas podem ser tomadas.

## ANOVA via teste Wald

- ▶ As Análises de Variância são sucessivos testes de hipótese que verificam a nulidade de determinados parâmetros.
- ▶ Isto geralmente é feito através de uma sequência de testes de Razão de Verossimilhança.
- ▶ Para as análises do tipo II e III é simples visualizar como gerar os quadros de Análise de Variância utilizando o teste Wald.
- ▶ Pois sempre estarão sendo comparados o modelo completo e o modelo sem determinada ou determinadas variáveis.
- ▶ Ou seja, basta então, para cada linha do quadro de Análise de Variância, especificar corretamente uma matriz  $L$  que represente de forma adequada a hipótese a ser testada.

## MANOVA via teste Wald

- ▶ Do mesmo modo que é feito para um modelo univariado, podemos chegar também a uma Análise de Variância Multivariada (MANOVA).
- ▶ Basta realizar sucessivos testes para avaliar o efeito de determinada variável nas R respostas simultaneamente.
- ▶ Portanto, a pergunta que a ser respondida seria: esta variável tem efeito diferente de 0 para todas as respostas?

Quem sou eu

Introdução

McGLM

Estimação e inferência

Teste Wald

Construção da matriz L

ANOVA via teste Wald

**Funções implementadas**

Próximos passos

8

## Funções implementadas



## Baseando-nos nas funções do pacote *car*, temos funções implementadas para

- ▶ Análises de Variância por variável resposta (ANOVA).
- ▶ Análises de Variância multivariadas (MANOVA). Note que no caso da MANOVA os preditores devem ser iguais para todas as respostas sob análise.
- ▶ Análise de variância focados no preditor linear matricial. O objetivo é verificar a significância dos parâmetros de dispersão.
- ▶ Hipóteses lineares gerais em que todos os elementos são especificadas pelo usuário, na qual é possível testar hipóteses sobre parâmetros de regressão, dispersão ou potência.

## Funções implementadas

Função	Descrição
mc_anova_I()	ANOVA tipo I (imita uma sequencial)
mc_anova_II()	ANOVA tipo II (nao bate com o car)
mc_anova_III()	ANOVA tipo III
mc_anova_disp()	ANOVA tipo III para dispersão
mc_manova_I()	MANOVA tipo I (imita uma sequencial)
mc_manova_II()	MANOVA tipo II (nao bate com o car)
mc_manova_III()	MANOVA tipo III
mc_manova_disp()	MANOVA tipo III para dispersão
mc_linear_hypothesis()	Hipóteses lineares gerais especificadas pelo usuário

Tabela 1

9

# Próximos passos

## O que temos até o momento

- ▶ Algum texto.
- ▶ Protótipo das funções.
- ▶ Conjuntos de dados para aplicação.

## Tarefas a cumprir

- ▶ Entender porquê nossos resultados não batem com o **car** na ANOVA tipo II.
- ▶ Avaliar relevância da ANOVA sequencial.
- ▶ Formular e executar o estudo de simulação.
- ▶ Documentar e reportar.

Considerando a área de pesquisa, o trabalho teria as seguintes contribuições:

1. Adaptar um teste existente para uma classe de modelos não usual mas com alto potencial de aplicação.
2. Realizar um estudo pesado de simulação para verificar o funcionamento da forma que estamos propondo.
3. Análisar de dados provenientes de estudos reais para demonstrar a aplicabilidade das funcionalidades.

# Obrigado!

Lineu Alberto Cavazani de Freitas  
lineuacf@gmail.com  
<https://lineu96.github.io/st/>  
PPG Informática



Quem sou eu

Introdução

McGLM

Estimação e inferência

Teste Wald

Construção da matriz L

ANOVA via teste Wald

Funções implementadas

Próximos passos